

¿Cuánto vale un departamento en Buenos Aires?

Predicción de precios inmobiliarios con aprendizaje automático

Análisis exploratorio, preparación iterativa y comparación de modelos sobre avisos de Properati en la Ciudad de Buenos Aires.

Base original	1.000.000 de avisos y 24 variables analíticas
Ámbito	Capital Federal; propiedades de 1 a 3 ambientes
Modelos	Árbol de decisión, Random Forest, KNeighbors e HistGradientBoosting

Lea Lambrecht

Contenido

1. Resumen ejecutivo
2. Objetivo y alcance
3. Fuente y estructura de los datos
4. Análisis exploratorio
5. Preparación y limpieza de datos
6. Evolución de los modelos de referencia
7. Segmentación de Puerto Madero
8. Modelos predictivos
9. Resultados registrados
10. Consideraciones metodológicas y limitaciones
11. Conclusiones

Bibliografía

Anexo

1. Resumen ejecutivo

Este proyecto desarrolla un proceso de estimación del precio publicado de propiedades de uno a tres ambientes en la Ciudad de Buenos Aires. El análisis utiliza avisos inmobiliarios de Properati y combina exploración de datos, depuración iterativa, tratamiento de valores faltantes y outliers, segmentación territorial y comparación de algoritmos de regresión.

La base original contiene 1.000.000 de observaciones y 25 columnas en el archivo. Al utilizar el identificador del aviso como índice, se trabajan 24 variables analíticas. El primer filtro conserva 257.546 publicaciones de Capital Federal. A partir de allí, cada transformación se evalúa con un árbol de decisión de profundidad tres para observar la evolución del RMSE.

La preparación reduce de manera sustancial el error registrado. Para el resto de CABA, el Random Forest alcanza un RMSE promedio de validación cruzada de 12.183,5; KNeighbors obtiene 12.236,9 e HistGradientBoosting 12.727,1. Para Puerto Madero, el Random Forest registra un RMSE promedio de 23.228,2. Estos valores corresponden a la ejecución documentada en el notebook.

El análisis también muestra que Puerto Madero requiere un tratamiento separado por su nivel de precios, la dispersión y el menor tamaño de muestra. La superficie cubierta aparece como la variable de mayor importancia en el Random Forest de ese segmento.

2. Objetivo y alcance

2.1 Objetivo

Crear un modelo de predicción del precio de propiedades en Capital Federal que tengan uno, dos o tres ambientes, documentando el efecto de las decisiones de preparación de datos y comparando modelos de aprendizaje automático.

2.2 Alcance

El análisis se basa en publicaciones de Properati, plataforma que agrega avisos inmobiliarios difundidos por distintos portales. La variable objetivo es el precio publicado, no el valor efectivo de una transacción. El estudio se concentra en Capital Federal y considera las tipologías Casa, Departamento y PH dentro del tipo de operación seleccionado en el notebook.

- Análisis exploratorio y descriptivo de la base.
- Limpieza, imputación y preparación de variables.
- Seguimiento del RMSE después de cada cambio.
- Separación de Puerto Madero del resto de los barrios.
- Comparación de Random Forest, KNeighbors e HistGradientBoosting.

3. Fuente y estructura de los datos

La fuente de datos es Properati. La base original se incorpora al repositorio como un ZIP dividido en partes menores a 25 MiB, debido a los límites de carga del navegador de GitHub. El notebook reconstruye automáticamente el ZIP y lee el archivo properati.csv sin extraerlo de forma permanente.

Base	Uso	Observaciones	Variables	Formato
properati.csv	Punto de partida del proceso completo	1,000,000	25 en archivo / 24 analíticas	12 partes ZIP

df3_limpio.csv	Checkpoint limpio de Puerto Madero entregado	1,035	19	CSV
df4_limpio.csv.gz	Checkpoint limpio del resto de CABA entregado	59,991	19	CSV gzip

Los checkpoints limpios son archivos entregados junto con el proyecto. La ejecución secuencial del notebook continúa aplicando filtros adicionales para construir las matrices finales de modelización, por lo que el número de observaciones de esas matrices es menor.

3.1 Variables originales

Variable	Descripción
id	Identificador del aviso.
start_date	Fecha de alta del aviso.
end_date	Fecha de baja del aviso.
created_on	Fecha de la primera versión del aviso.
lat / lon	Coordenadas geográficas de la propiedad.
l1 a l6	Niveles administrativos y geográficos.
rooms	Cantidad de ambientes.
bedrooms	Cantidad de dormitorios.
bathrooms	Cantidad de baños.
surface_total	Superficie total en metros cuadrados.
surface_covered	Superficie cubierta en metros cuadrados.
price / currency	Precio publicado y moneda.
price_period	Periodicidad del precio cuando corresponde.
title / description	Texto del anuncio.
property_type	Tipo de propiedad.
operation_type	Tipo de operación.

4. Análisis exploratorio

La exploración inicial revisa dimensiones, primeras y últimas observaciones, tipos de datos, valores únicos, frecuencias, medidas descriptivas, medianas, modas, varianzas y correlaciones numéricas. Esta etapa permite identificar variables con gran cantidad de faltantes, escalas incompatibles, categorías poco frecuentes y registros geográficamente inconsistentes.

El filtro por Capital Federal conserva 257.546 observaciones. En esa etapa se detectan faltantes relevantes en barrio, coordenadas, ambientes, dormitorios, baños y superficies. También se observa que la base combina diferentes monedas, tipos de operación y tipologías de propiedad, por lo que no puede modelarse directamente sin una depuración previa.

Las columnas de latitud y longitud se encuentran intercambiadas en la base utilizada y se renombran. Se eliminan los niveles geográficos l1, l4, l5 y l6, además de price_period, por su escasa utilidad para el objetivo o por su calidad de información.

5. Preparación y limpieza de datos

5.1 Barrio y coordenadas

Para la variable l3 se calculan coordenadas promedio por barrio y se construye un diccionario de referencia. Los valores faltantes se imputan a partir de las coordenadas disponibles y se eliminan los casos que no pueden asignarse. La categoría Distrito Audiovisual se reemplaza por Chacarita.

Posteriormente se imputan coordenadas faltantes con los promedios barriales y se eliminan puntos fuera de los límites definidos para Capital Federal.

5.2 Precio, moneda, fechas y texto

Los precios publicados en pesos argentinos se convierten a dólares utilizando el cociente aplicado en el notebook. Se eliminan publicaciones sin precio y registros sin moneda. La fecha de finalización 9999-12-31 se corrige para evitar un año inválido y se descartan avisos sin título.

5.3 Tipología y operación

Se conservan Casa, Departamento y PH. Luego se analiza la distribución por tipo de operación y se selecciona la categoría utilizada en la modelización. Este filtro produce una reducción marcada del volumen de observaciones y del RMSE de referencia.

5.4 Ambientes, dormitorios y baños

Los faltantes se imputan con medianas calculadas por barrio. También se establecen límites coherentes con el objetivo de analizar propiedades pequeñas y se revisan inconsistencias entre ambientes, dormitorios y baños. Estas decisiones buscan evitar valores extremos o errores de carga que distorsionen los modelos.

5.5 Superficies

Las superficies total y cubierta se imputan por barrio. Se revisan sus distribuciones, se aplican rangos admisibles y se intercambian los valores cuando la superficie cubierta supera a la total. El tratamiento se ejecuta de manera separada en el resto de CABA y en Puerto Madero.

5.6 Precio por metro cuadrado y outliers

Para el resto de CABA se limita el precio a un rango definido y se calcula el precio por metro cuadrado. Luego se construye un precio de referencia por barrio multiplicando el precio por metro cuadrado agregado por la superficie total. La diferencia entre el precio real y el precio ajustado se utiliza para identificar y eliminar publicaciones atípicas mediante umbrales basados en desvíos estándar.

Puerto Madero recibe reglas específicas de superficie y precio. El precio de referencia se calcula dentro del propio segmento y la diferencia respecto del precio publicado se utiliza para revisar outliers. Este procedimiento reduce el RMSE del árbol de referencia de 228.366 a 71.969.

6. Evolución de los modelos de referencia

Después de cada cambio se entrena un DecisionTreeRegressor con profundidad máxima tres, criterio friedman_mse y semilla 42. Este árbol no se plantea como modelo final, sino como instrumento para medir cómo cambia el error a medida que se depura la información.

Etapa	Cambio acumulado	Observaciones	RMSE
1	Línea de base con variables numéricas y faltantes reemplazados por cero	257,546	899,118
2	Depuración e imputación de barrio (13)	236,253	876,814
3	Imputación de coordenadas y control geográfico de CABA	232,907	918,928

4	Conversión y depuración de precio, moneda, fecha y título	225,152	406,063
5	Selección de Casa, Departamento y PH	170,450	236,119
6	Selección del tipo de operación analizado	83,791	87,117
7	Tratamiento de ambientes	83,791	87,117
8	Tratamiento de dormitorios	81,372	119,207
9	Tratamiento de baños	81,141	162,936
10	Imputación de superficie total	81,141	163,215
11	Imputación de superficie cubierta	81,141	162,480
12	Depuración de superficies en el resto de CABA	74,742	122,641
13	Consistencia entre dormitorios y baños	73,868	89,203
14	Rango de precios y precio por metro cuadrado	70,696	27,412
15	Tratamiento de outliers con precio de referencia por barrio	49,021	17,204
16	Línea de base específica de Puerto Madero	1,151	228,366
17	Tratamiento específico de outliers de Puerto Madero	552	71,969
18	Variables dummy de barrio en el resto de CABA	49,021	17,204




Figura 1. Evolución del RMSE registrado durante la preparación de datos.

El RMSE no disminuye de forma monótonica: algunas imputaciones y restricciones aumentan temporalmente el error porque modifican la composición y la variabilidad de la muestra. La mejora más fuerte se observa al controlar el rango de precios y construir referencias por barrio para estudiar los outliers.




Figura 2. Evolución del tamaño de la muestra en las 18 etapas.

7. Segmentación de Puerto Madero

Tras el tratamiento general, el análisis se divide entre Puerto Madero y el resto de CABA. En la primera separación se registran 1.151 observaciones para Puerto Madero y 79.990 para los demás barrios. Los filtros posteriores reducen las matrices utilizadas en los modelos de referencia a 552 y 49.021 observaciones, respectivamente.

La separación está justificada por la diferencia en niveles de precio, superficies y dispersión. Aplicar los mismos umbrales a toda la Ciudad podría eliminar casos válidos de Puerto Madero o distorsionar el ajuste del resto de los barrios.

8. Modelos predictivos

8.1 Random Forest

Random Forest combina múltiples árboles entrenados sobre muestras y subconjuntos de variables. La búsqueda de hiperparámetros del resto de CABA utiliza RandomizedSearchCV con siete particiones. La mejor configuración registrada incluye 300 árboles, profundidad máxima 15 y cinco variables consideradas en cada división.

Para Puerto Madero, la mejor configuración registrada utiliza 300 árboles, profundidad máxima 15 y siete variables por división. El RMSE promedio informado es 23.228,2.

8.2 KNeighbors

KNeighbors estima el precio a partir de propiedades cercanas en el espacio de variables. Se prueban cantidades de vecinos, esquemas de ponderación y métricas de distancia. La mejor combinación registrada utiliza 30 vecinos, ponderación por distancia y métrica cityblock, con validación cruzada de diez particiones.

8.3 HistGradientBoosting

HistGradientBoosting construye árboles de manera secuencial para corregir los errores anteriores. La mejor configuración registrada utiliza 1.000 iteraciones, profundidad máxima 18, tasa de aprendizaje 0,4 y regularización L2 de 0,1, evaluada con diez particiones.

9. Resultados registrados

Segmento	Modelo	RMSE promedio	Folds	Mejores parámetros
Resto de CABA	Random Forest	12,183.5	7	n_estimators=300; max_features=5; max_depth=15
Resto de CABA	KNeighbors	12,236.9	10	weights=distance; n_neighbors=30; metric=cityblock
Resto de CABA	HistGradientBoosting	12,727.1	10	max_iter=1000; max_depth=18; learning_rate=0.4; l2_regularization=0.1
Puerto Madero	Random Forest	23,228.2	7	n_estimators=300; max_features=7; max_depth=15




Figura 3. Comparación de los RMSE registrados para el resto de CABA.

Random Forest obtiene el menor RMSE promedio registrado en el resto de CABA, con una diferencia pequeña respecto de KNeighbors. HistGradientBoosting queda en tercer lugar dentro de la comparación documentada.

9.1 Importancia de variables en Puerto Madero

El notebook calcula la importancia de variables utilizando el mejor estimador de Random Forest de Puerto Madero. La superficie cubierta representa aproximadamente el 31,3 % de la importancia. Le siguen la diferencia entre precio real y ajustado, el precio ajustado y la superficie total.

Variable	Importancia
surface_covered	0.3133
diferencia_precio_real_ajustado	0.2410
precio_ajustado	0.2091
surface_total	0.1929
lon	0.0299
lat	0.0084
rooms	0.0038
bedrooms	0.0008
bathrooms	0.0007




Figura 4. Importancia de variables registrada para Puerto Madero.

10. Consideraciones metodológicas y limitaciones

10.1 Variables derivadas del precio

El precio ajustado se obtiene a partir del precio por metro cuadrado calculado con el mismo conjunto de avisos y la diferencia precio real-ajustado utiliza directamente el valor objetivo. Estas variables son pertinentes para detectar outliers y describir la relación entre una publicación y su barrio. Sin embargo, no estarían disponibles para una propiedad nueva cuyo precio se pretende estimar.

Por este motivo, los RMSE finales deben interpretarse como resultados exploratorios del proceso desarrollado. Una validación orientada a producción debería calcular referencias únicamente con datos de entrenamiento y excluir de los predictores cualquier variable que use directa o indirectamente el precio objetivo.

10.2 Otras limitaciones

- La variable objetivo es el precio publicado y no el precio final de cierre.
- La base corresponde a un período histórico y no representa necesariamente el mercado actual.

- No se incorporan atributos como antigüedad, estado, expensas, cochera, amenities, piso u orientación.
- Los textos de título y descripción se conservan, pero no se transforman en predictores.
- Puerto Madero tiene una muestra considerablemente menor que el resto de CABA.
- La base puede incluir publicaciones repetidas de una misma propiedad con identificadores distintos.
- La búsqueda aleatoria no fija una semilla, por lo que una nueva ejecución puede seleccionar combinaciones diferentes.

10.3 Recomendaciones de evolución

1. Separar entrenamiento y prueba antes de calcular estadísticas de barrio o reglas de outliers.
2. Construir un pipeline que aplique las mismas transformaciones a datos nuevos.
3. Agregar variables inmobiliarias y atributos extraídos del texto de los avisos.
4. Evaluar una validación temporal para simular la predicción de publicaciones futuras.
5. Mantener un modelo o estrategia específica para segmentos de lujo como Puerto Madero.
6. Incorporar intervalos de predicción y reglas de revisión manual para casos extremos.

11. Conclusiones

El trabajo muestra que la calidad de los datos y la definición de la población son determinantes en la predicción inmobiliaria. La depuración geográfica, la conversión de moneda, la selección de tipologías y operaciones, las imputaciones por barrio y el control de superficies modifican sustancialmente el RMSE.

La segmentación de Puerto Madero permite reconocer una estructura de precios distinta y aplicar límites específicos. Random Forest obtiene el mejor RMSE promedio registrado en el resto de CABA y se utiliza también para Puerto Madero, donde la superficie cubierta es la variable de mayor importancia.

El proyecto documenta de manera completa la experimentación realizada. Como siguiente paso, la metodología puede fortalecerse mediante pipelines reproducibles, validación temporal y exclusión de variables derivadas del precio cuando el objetivo sea estimar propiedades nuevas.

Bibliografía

Breiman, L. (2001). Random Forests. Machine Learning, 45, 5-32.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Properati. Plataforma de avisos inmobiliarios utilizada como fuente de datos.

pandas. Documentación de lectura y transformación de datos tabulares.

scikit-learn. Documentación de DecisionTreeRegressor, RandomForestRegressor, KNeighborsRegressor, HistGradientBoostingRegressor y RandomizedSearchCV.

Anexo

A. Estructura de los archivos de datos

La base original se distribuye en 12 fragmentos binarios consecutivos. Todos deben permanecer en la carpeta data con sus nombres originales. El notebook los concatena en orden para reconstruir properati.csv.zip. El manifiesto con tamaños y SHA-256 se encuentra en results/data_manifest.csv.

Archivo	Tamaño
properati.csv.zip.part01	20.00 MiB
properati.csv.zip.part02	20.00 MiB
properati.csv.zip.part03	20.00 MiB
properati.csv.zip.part04	20.00 MiB
properati.csv.zip.part05	20.00 MiB
properati.csv.zip.part06	20.00 MiB
properati.csv.zip.part07	20.00 MiB
properati.csv.zip.part08	20.00 MiB
properati.csv.zip.part09	20.00 MiB
properati.csv.zip.part10	20.00 MiB
properati.csv.zip.part11	20.00 MiB
properati.csv.zip.part12	6.39 MiB
df3_limpio.csv	1.36 MiB
df4_limpio.csv.gz	17.81 MiB

B. Resultados de las 18 etapas

Modelo	Observaciones	RMSE
1	257,546	899,118.2113
2	236,253	876,814.3182
3	232,907	918,927.6492
4	225,152	406,063.3050
5	170,450	236,118.5133
6	83,791	87,116.7263
7	83,791	87,116.7263
8	81,372	119,206.6262
9	81,141	162,935.6568
10	81,141	163,215.3421
11	81,141	162,479.7131
12	74,742	122,640.9000
13	73,868	89,203.0827
14	70,696	27,412.0705
15	49,021	17,203.5851
16	1,151	228,366.4404
17	552	71,969.1663
18	49,021	17,203.5851

C. Variables de los checkpoints limpios

Variable	Tipo en df3	Tipo en df4
ad_type	object	object
start_date	object	object
end_date	object	object
created_on	object	object
lon	float64	float64
lat	float64	float64
l2	object	object
l3	object	object

rooms	float64	float64
bedrooms	float64	float64
bathrooms	float64	float64
surface_total	float64	float64
surface_covered	float64	float64
currency	object	object
title	object	object
description	object	object
property_type	object	object
operation_type	object	object
price	float64	float64

D. Archivos del repositorio

- ``notebooks/caba-apartment-price-prediction.ipynb``: análisis completo con rutas relativas.
- ``reports/``: informe en Word y PDF.
- ``results/iterative_model_results.csv``: evolución de observaciones y RMSE.
- ``results/recorded_model_search_results.csv``: mejores resultados de la búsqueda documentada.
- ``results/puerto_madero_random_forest_importance.csv``: importancia de variables registrada.
- ``results/data_manifest.csv``: tamaños y checksums de los archivos de datos.